

THEJUS MAHAJAN PH.D.

Clinical Data Scientist — Biostatistik & Datenpipeline-Engineering

+49 1525 9697629
thejusmahajan.github.io

@ thejus.mahajan@uni-hamburg.de
Reventlowstraße 17, 22605 Hamburg

*30.09.1992 (Talikulam, Indien) Verheiratet Staatsangehörigkeit: Indisch



PROFIL

- Computational Scientist (Promotion, Post-doc) mit Erfahrung in klinischem Datenpipeline-Engineering, Biostatistik und Bioinformatik.
- Kernkompetenzen: R (tidyverse, Shiny, tidymodels), Python (JAX, Pandas), SQL, Git.
- Praktikum bei HealthTwist GmbH: Refactoring einer Produktions-R-Pipeline für das DeGIR-Qualitätsregister (143.000+ Patientendatensätze, ~300 Kliniken), Aufbau eines R-Shiny-Dashboards, Erstellung des R-Pakets degirtools.
- Verfügbar ab Mitte April 2026.
- Offen für: Klinische Datenwissenschaft, Biostatistik, Bioinformatik, Dateningenieurwesen, Research Software Engineering.

BERUFSERFAHRUNG

Praktikum – Klinische Biostatistik & Datenpipeline-Engineering HealthTwist GmbH

02/2026 - 04/2026 Berlin, Deutschland

Klinische Datenforschung und -entwicklung unter Dr. Andreas Busjahn

- Refactoring einer monolithischen 1.834-Zeilen R-Datenpipeline (tidyverse) für das interventionell-radiologische Qualitätsregister Deutschlands (DeGIR); 143.000+ Patientendatensätze von ~300 Kliniken. Reduktion auf 1.349 Zeilen (-26,5%) mit byte-identischer Ausgabe, verifiziert via `identical()`.
- Externalisierung von 257 hardcodierten Korrekturregeln in 8 Konfigurations-CSV-Dateien; ermöglicht Bearbeitung durch Nicht-Programmierer.
- Ersetzung von 360 veralteten Funktionsaufrufen in 4 Pipeline-Dateien; Modernisierung auf aktuelle tidyverse-Standards.
- Erstellung des R-Pakets `degirtools` (9 exportierte Funktionen, `roxygen2`-Dokumentation, `devtools::check()` bestanden) durch Extraktion wiederverwendbarer Logik aus einer 767-Zeilen-Hilfsdatei.
- Entdeckung von 2 vorbestehenden Fehlern durch systematische Codeanalyse; dokumentiert und originales Verhalten für Supervisor-Review beibehalten — Demonstration von Produktionscode-Disziplin.
- Aufbau eines interaktiven R-Shiny-Dashboards (6 Module: Übersicht, Interventionen, Komplikationen, Strahlendosen, Erfolgsraten, Info) mit `plotly`, `DT` und `bslib`. Deployment auf `shinyapps.io` mit DSGVO-konformen synthetischen Daten.
- Erstellung von Tidymodels-Lehrmaterialien (Quarto/GitHub) als Ersatz für das veraltete `caret`-Framework für ML-Workflows in R.

Weiterbildung – Bioinformatik und Biostatistik

CQ Beratung + Bildung GmbH

08/2025 - 02/2026 Berlin, Deutschland

Angewandte Bioinformatik und Biostatistik

- Programmiermethodik: Shell (BASH), Python (objektorientiert), R.
- Bioinformatik-Datenbanken (NCBI, Biopython, SQL) und Sequenzanalyse.
- NGS-Analysepipelines (Next-Generation Sequencing; Nextflow, Galaxy); Strukturbioinformatik.
- Biostatistik (R/Bioconductor): ANOVA, PCA, HCA, multivariate Analyse, Markov-Ketten.
- Abschlussprojekt: Erstellung einer reproduzierbaren Nextflow-(DSL2)-Pipeline für die Sequenzanalyse des Hepatitis-Delta-Virus — automatisierter NCBI-Download, MAFFT-Alignment und trimAI-Trimming mit Conda-verwalteten Abhängigkeiten (GitHub).

Gastwissenschaftler (parallel zur Weiterbildung ab 08/2025)

Helmholtz-Zentrum Hereon, Ökosystemmodellierung

05/2025 - 10/2025 Geesthacht, Deutschland

STÄRKEN



Klinische Datenpipeline-Engineering

Refactoring einer Produktions-Datenpipeline (1.834 Zeilen, 143K Datensätze, ~300 Kliniken) mit 26,5% Codereduktion. Erstellung des R-Pakets `degirtools`. Byte-Level-Verifizierung nach jeder Änderung via `identical()`.



Biostatistik & Maschinelles Lernen

Versiert in multivariater Analyse (PCA, ANOVA), klinischer Ergebnisanalyse, Entwicklung von Machine-Learning-Workflows mit `tidymodels` und Kreuzvalidierung.



Bioinformatik & Reproduzierbare Forschung

Versiert in NGS-Datenanalyse, Erstellung reproduzierbarer Pipelines mit Nextflow (DSL2), Bioconductor-Workflows und Sicherstellung DSGVO-konformer Datenverarbeitung.

TECHNISCHE FÄHIGKEITEN

Programmierung

R (tidyverse, Shiny, tidymodels, Bioconductor), Python (JAX, Pandas, NumPy), SQL, Fortran, C++, BASH

Klinische Daten & Biostatistik

Medizinische Registerpipelines, DSGVO-Konformität, multivariate Analyse, PCA, ANOVA, Survival-Analyse-Konzepte, klinische Endpunkte

Dateningenieurwesen

Pipeline-Refactoring, konfigurationsgetriebene ETL, `identical()` Verifizierung, R-Shiny-Dashboards, große Datensätze (HDF5, NetCDF)

Bioinformatik

NGS-Analyse, Nextflow (DSL2), Sequenzanalyse, Bioconductor

Werkzeuge

Git/GitHub, Linux/Unix, HPC-Cluster, Conda, LaTeX, Docker-Konzepte

SPRACHEN

Englisch



Verhandlungssicher (C1)

Deutsch



B1 (Goethe-Zertifikat), B2 in Vorbereitung

Französisch



Grundkenntnisse

Modellierung evolutionärer Prozesse in Meeresökosystemen; Simulation langfristiger Umweltauswirkungen mittels fortgeschrittener Rechenmethoden. Fertigstellung des rechnergestützten Modellierungs-Frameworks und Aufbereitung der Simulationsdaten für eine Peer-Review-Publikation.

Jobsuche & Deutschkurs

02/2025 - 04/2025 Hamburg, Deutschland

Aktive Stellensuche und Erwerb der deutschen Sprache (Goethe-Zertifikat B1).

Wissenschaftlicher Mitarbeiter (Post-doc)

Universität Hamburg, Institut für Marine Ökosystem- und Fischereiwiss.

08/2021 - 01/2025 Hamburg, Deutschland

Marine Ökosystemmodellierung

- Elternzeit von 01/2024 bis 12/2024.
- Modellentwicklung: Entwicklung des "Cyanobacteria Life Cycle" (CLC)-Modells im ERGOM-Framework für Klimaerwärmungsprojektionen.
- Hochleistungsrechnen (HPC): Übersetzung eines Legacy-Fortran-Modells in eine hochperformante Python-Engine (Google JAX, TPU/GPU-Parallelisierung). Verarbeitung großer NetCDF-Datensätze in Linux-HPC-Umgebung.

Berufliche Neuorientierung

04/2021 - 07/2021 Hamburg, Deutschland

Umzug von Indien nach Deutschland und aktive Stellensuche.

Physik-Dozent & Schachtrainer

Freiberuflich / Tutorwaves Solutions Inc (ab 08/2020)

10/2018 - 03/2021 Kerala, Indien

Freiberufliche Physik-Nachhilfe und Coaching von Schachmannschaften auf Landesebene; ab 08/2020 bei Tutorwaves: Erstellung von Physikhalten und Betreuung von Schülern in den USA und Australien.

Doktorand in Astrochemie

Université Paris-Saclay

10/2015 - 09/2018 Orsay, Frankreich

Durchführung von Atomkollisionsexperimenten, Datenanalyse und Ergebnismodellierung.

- Erfassung und Verarbeitung von Terabytes an Rohdaten aus Tandem-Teilchenbeschleunigerexperimenten.
- C++ Code-Optimierung: Verbesserung bestehender Algorithmen zur Rauschunterdrückung, Signalglättung und Konvertierung von Rohdaten in mehrdimensionale Strukturen.
- Entwicklung eines molekularen Fragmentierungsmodells zur Vorhersage chemischer Reaktionen im Weltraum (Beitrag zur KIDA-Datenbank).

AUSBILDUNG

Promotion in Astrochemie

Université Paris-Saclay, Institute of Molecular Sciences (ISMO)

10/2015 - 09/2018 Orsay, Frankreich

Supervisor: Dr. Karine Béroff. Diss.: *Excitation and fragmentation of C_nN^+ ($n=1-3$) in collisions with He atoms at intermediate velocity.*

M.Sc. in Physik

National Institute of Technology Calicut, Indien

07/2012 - 12/2014 Calicut, Indien

Mit Auszeichnung (CGPA 8,71/10).

Forschungsprojekt – Theoretische Atomphysik

IIT Mandi (unter Dr. Hari Varma)

02/2015 - 08/2015 Mandi, Indien

Theoretische Atomphysik; teilweise remote.

B.Sc. in Physik

University of Calicut, Indien

06/2009 - 04/2012 Thrissur, Indien

B+ (CGPA 3,49/4,0).

Malayalam



Muttersprache

Tamil



Verhandlungssicher

Hindi



Grundkenntnisse

WEITERBILDUNG / KURSE

High Performance Computing (HPC) Training

Jülich Supercomputing Center (JSC),
Forschungszentrum Jülich

MITx: 7.00x Introduction to Biology – The Secret of Life

Umfassende Kursarbeit zu Genetik, Biochemie und Molekularbiologie.

PUBLIKATIONEN

T. Mahajan et al. *J. Phys.: Conf. Ser.*, 1412:142026, 2020.

T. Idbarkach et al. *Astron. Astrophys.*, 628:A75, 2019.

T. Mahajan et al. *J. Phys. B*, 2019.

T. Idbarkach et al. *J. Phys. B*, 51(24):245201, 2018.

T. Idbarkach et al. *J. Phys.: Conf. Ser.*, 1412(11):112028, 2020.

Google Scholar Profil

Hamburg, 18. April 2026

Dr. Thejus Mahajan