

# THEJUS MAHAJAN PH.D.

Computational Biologist – KI & Multi-Omics

+49-15259697629

thejusmahajan.github.io

@ thejus.mahajan@uni-hamburg.de

Hamburg, Germany

30.09.1992 (Talikulam, Indien)

Verheiratet



## PROFIL

- **Schwerpunkt:** KI-gestützte Multi-Omics-Integration, Deep Learning und Bioinformatik-Pipelineentwicklung für die translationale Biomedizin.
- **Kernkompetenzen:** Python (JAX, PyTorch-Konzepte, Scikit-learn, Pandas), R (Bioconductor, Tidymodels), Nextflow (DSL2), BASH.
- **Aktuelles Ziel:** Entwicklung von KI-Frameworks für Multi-Omics-Datenintegration zur Förderung der Forschung in Stammzellbiologie und komplexen Komorbiditätsnetzwerken.

## BERUFSERFAHRUNG

### Praktikum – Bioinformatik & Datenpipeline-Engineering

HealthTwist GmbH

02/2026 - 04/2026

Berlin, Deutschland

Klinische Datenforschung und -entwicklung unter Dr. Andreas Busjahn

- Refactoring einer monolithischen 1.834-Zeilen R-Datenpipeline (tidyverse) für das interventionell-radiologische Qualitätsregister Deutschlands (DeGIR); 143.000+ Patientendatensätze von ~300 Kliniken. Reduktion auf 1.348 Zeilen (-26,5%) mit byte-identischer Ausgabe, verifiziert via `identical()`.
- Externalisierung von 257 hardcodierten Korrekturregeln in 8 Konfigurations-CSV-Dateien; ermöglicht Bearbeitung durch Nicht-Programmierer.
- Ersetzung von 357 veralteten Funktionsaufrufen in 4 Pipeline-Dateien; Modernisierung auf aktuelle tidyverse-Standards.
- Erstellung des R-Pakets `degirtools` (9 exportierte Funktionen, roxygen2-Dokumentation, devtools: `:check()` bestanden) durch Extraktion wiederverwendbarer Logik aus einer 767-Zeilen-Hilfsdatei.
- Entdeckung von 2 vorbestehenden Fehlern durch systematische Codeanalyse; dokumentiert und originales Verhalten für Supervisor-Review beibehalten – Demonstration von Produktionscode-Disziplin.
- Aufbau eines interaktiven R-Shiny-Dashboards (6 Module: Übersicht, Interventionen, Komplikationen, Strahlendosen, Erfolgsraten, Info) mit plotly, DT und bslib. Deployment auf shinyapps.io mit DSGVO-konformen synthetischen Daten.
- Erstellung von Tidymodels-Lehrmaterialien (Quarto/GitHub) als Ersatz für das veraltete caret-Framework für ML-Workflows in R.

### Weiterbildung – Bioinformatik und Biostatistik

CQ Beratung + Bildung GmbH

08/2025 - 02/2026

Berlin, Deutschland

Anwendungsorientierte Bioinformatik und Biostatistik

- Programmiermethodik: Shell (BASH), Python (objektorientiert), R.
- Bioinformatik-Datenbanken (NCBI, Biopython, SQL) und Sequenzanalyse.
- NGS-Analysepipelines (Nextflow, Galaxy); Strukturbioinformatik.
- Klinische Biostatistik (R/Bioconductor, ANOVA, PCA, HCA, Survival-Analyse); DSGVO/BDSG-Konformität.
- Abschlussprojekt: Erstellung einer reproduzierbaren Nextflow-(DSL2)-Pipeline für die Sequenzanalyse des Hepatitis-Delta-Virus – automatisierter NCBI-Download, MAFFT-Alignment und trimAl-Trimming mit Conda-verwalteten Abhängigkeiten (GitHub).

### Gastwissenschaftler

Helmholtz-Zentrum Hereon, Ökosystemmodellierung

05/2025 - 10/2025

Geesthacht, Deutschland

Computational Biologist & Systemmodellierer

- Leitung der Forschung zur Modellierung evolutionärer Prozesse in Meeresökosystemen.

## STÄRKEN



### Datenpipeline-Engineering

Refactoring einer Produktions-Datenpipeline (1.834 Zeilen, 143K Datensätze, ~300 Kliniken) mit 26,5% Codereduktion. Erstellung des R-Pakets `degirtools`. Byte-Level-Verifizierung nach jeder Änderung via `identical()`.



### Komplexe Problemlösung

Lösung eines kritischen Datenverlusts durch Erstellung einer Fortran-Simulation zur Korrektur eines falsch platzierten Teilchendetektors; Neuberechnung der Ergebnisse mittels Multisensor-Daten.



### KI & Multi-Omics-Integration

Tiefgehende Expertise in Tensoroperationen und GPU/TPU-beschleunigtem Computing (Google JAX) – die rechnerische Grundlage für Graph Neural Networks und Variational Autoencoders. Kombination von statistischer Genomik (R/Bioconductor) mit Python-basiertem Deep Learning zur Integration hochdimensionaler biologischer Datensätze.

## TECHNISCHE FÄHIGKEITEN

### Programmierung

Python (JAX, Pandas, NumPy, Scikit-learn, Biopython), R (Bioconductor, Tidymodels), SQL, BASH

### Bioinformatik

Multi-Omics-Datenintegration, Nextflow (DSL2), NGS-Analyse, Multiple Sequenz-Alignment (MAFFT), Sequenz-Trimming (trimAl), NCBI / Entrez

### KI & Deep Learning

Google JAX (TPU/GPU), PyTorch & TensorFlow (Konzepte), Graph Neural Networks (konzeptuell), Scikit-learn, Tidymodels, PCA, Clustering

### Dateningenieurwesen

Hardwarebeschleunigung (TPU/GPU), Verarbeitung groß, R Shiny, devtools/roxygen2er Datensätze (HDF5, NetCDF), Pipeline-Entwicklung

### Werkzeuge

Linux/Unix, Git, HPC-Cluster, Conda

## WEITERBILDUNG / KURSE

IBM: Machine Learning with Python; Introduction to AI

Coursera (in Bearbeitung)

- Anwendung fortgeschrittener Rechenmethoden zur Simulation langfristiger Umweltauswirkungen.
- Fertigstellung des rechnergestützten Modellierungs-Frameworks und Aufbereitung der Simulationsdaten für eine Peer-Review-Publikation.

## Jobsuche & Deutschkurs

### Hamburg, Deutschland

📅 02/2025 - 04/2025 📍 Hamburg, Deutschland

Aktive Stellensuche und Erwerb der deutschen Sprache (Goethe B1-Zertifikat).

## Post-doctoral Scientist

### Universität Hamburg, Institut für Marine Ökosystem- und Fischereiwiss.

📅 08/2021 - 01/2025 📍 Hamburg, Deutschland

Meeresökosystem-Modellierung

- *Elternzeit von 01/2024 bis 12/2024.*
- Modellentwicklung: Entwicklung des neuartigen "Cyanobacteria Life Cycle" (CLC)-Modells im ERGOM-Framework für Klimaerwärmungsprojektionen.
- Hochleistungsrechnen & ML: Leitung der Übersetzung eines Legacy-Fortran-Modells in eine hochperformante Python-Simulationsengine. Nutzung von **Google JAX**-Vektorisierung und branchless-Logik für massive Parallelisierung (direkte Kompatibilität mit **TPUs und GPUs**).
- Diese Architektur bildet eine starke Grundlage in Tensoroperationen, die Deep-Learning-Frameworks wie **PyTorch** und **TensorFlow** zugrunde liegen.

## Berufliche Neuorientierung

### Kerala, Indien

📅 04/2021 - 07/2021 📍 Kerala, Indien

Umzug von Indien nach Deutschland und aktive Stellensuche.

## Physik-Dozent

### Tutorwaves Solutions Inc / Freiberuflich

📅 10/2018 - 03/2021 📍 Kerala, Indien

Erstellung von Physikinhalten für Aufnahmeprüfungen und Coaching von Schachmannschaften auf Landesebene.

## Doktorand in Astrochemie

### Université Paris-Saclay

📅 10/2015 - 09/2018 📍 Orsay, Frankreich

Leitung von Atomkollisionsexperimenten, Datenanalyse und Ergebnismodellierung.

- Erfassung und Verarbeitung von Terabytes an Rohdaten aus Tandem-Teilchenbeschleunigerexperimenten.
- C++ Signalverarbeitung, Algorithmenentwicklung und molekulare Fragmentierungsmodellierung (KIDA-Datenbank).

## High Performance Computing (HPC) Training

Jülich Supercomputing Center (JSC),  
Forschungszentrum Jülich

## MITx: 7.00x Introduction to Biology - The Secret of Life

Umfassende Kursarbeit zu Genetik, Biochemie und Molekularbiologie.

## AUSGEWÄHLTE PROJEKTE

### Hepatitis-Delta-Virus-Pipeline • GitHub

Nextflow (DSL2)-Pipeline für virale Sequenzanalyse: NCBI Entrez-Download, MAFFT-Alignment, trimAl-Trimming, Conda-verwaltete Abhängigkeiten.

### JAX/TPU Hochleistungssimulator • GitHub

Portierung eines Legacy-Fortran-Modells in eine modulare Python-Architektur mit Google JAX. Entwicklung branchless, vektorisierter Logik für massive TPU/GPU-Parallelisierung.

### Introduction to Tidymodels • GitHub

Lehrskript für ML in R: recipes, parsnip, workflows und yardstick mit dem Palmer Penguins-Datensatz.

### Berlin Tree Analysis • GitHub

Interaktives Jupyter-Notebook zur Analyse von 5 Jahren Baumpflanzungsdaten in Berlin mit Python, Pandas und Seaborn.

## PUBLIKATIONEN

5 begutachtete Fachartikel • 🎓 Google Scholar Profil

## SPRACHEN

### Englisch



Verhandlungssicher (C1)

### Deutsch



B1 – Goethe-Zertifikat

### Französisch



Grundkenntnisse

### Malayalam



Muttersprache

### Tamil



Verhandlungssicher

### Hindi



Grundkenntnisse

## AUSBILDUNG

## Promotion in Astrochemie

### Université Paris-Saclay, Institute of Molecular Sciences (ISMO)

📅 10/2015 - 09/2018 📍 Orsay, Frankreich

Diss.: *Excitation and fragmentation of  $C_nN^+$  ( $n=1-3$ ) in collisions with He atoms at intermediate velocity.*

## Forschungsprojekt – Theoretische Atomphysik

### IIT Mandi (unter Dr. Hari Varma)

📅 02/2015 - 08/2015 📍 Mandi, Indien

Theoretische Atomphysik; teilweise remote.

## M.Sc. in Physik

National Institute of Technology Calicut, Indien

📅 07/2012 - 12/2014

📍 Calicut, Indien

First Class with Distinction (CGPA 8.71/10).

Hamburg, 11. April 2026

## B.Sc. in Physik

University of Calicut, Indien

📅 06/2009 - 04/2012

📍 Thrissur, Indien

B+ (CGPA 3,49/4,0). Anschl. 05–06/2012: Aufnahmeprüfung und Zulassung zum M.Sc.



**Dr. Thejus Mahajan**