

Dr. Thejus Mahajan
Kieler Straße 634
22527 Hamburg
0152 59697629
thejus.mahajan@uni-hamburg.de

Octapharma Biopharmaceuticals GmbH
Frau Dorothee Schaupp
Im Neuenheimer Feld 590
69120 Heidelberg

Hamburg, 10. März 2026

Bewerbung als Scientist R&D Molecular Design (m/w/d) – Job ID: 61464

Sehr geehrte Frau Schaupp,

die Identifikation und Optimierung therapeutischer Antikörper durch Phage-Display-Technologien generiert massive, hochdimensionale NGS-Datenmengen. Um diese Vielfalt (Diversity) effizient zu durchdringen und in zielgerichtete *Directed-Evolution*-Strategien zu überführen, bedarf es robuster, reproduzierbarer und hochskalierbarer bioinformatischer Workflows. Als erfahrener Computational Biologist bewerbe ich mich darum, die Position in Ihrer Abteilung Molecular Design als genau diese dedizierte, rechnergestützte Brücke zwischen Ihren experimentellen Screening-Teams und der datengetriebenen Kandidatenoptimierung auszufüllen.

In den vergangenen fünf Jahren habe ich mich darauf spezialisiert, komplexe biologische Fragestellungen in leistungsstarken Code zu übersetzen. Während meiner Tätigkeit am Institut für Marine Ökosystem- und Fischereiwissenschaften der Universität Hamburg (sowie durch fortlaufende Spezialisierungsprojekte) habe ich fundierte Erfahrungen in der Entwicklung moderner Datenpipelines gesammelt.

Ein zentraler Pfeiler meiner Expertise, der für Ihre Anforderungen im NGS-Bereich hochrelevant ist, ist die Konstruktion reproduzierbarer Workflows mittels **Nextflow (DSL2)**. Ich habe Analysepipelines entwickelt, die Sequenzdaten aus biologischen Datenbanken (z. B. NCBI) automatisch abrufen, kuratieren und über Algorithmen wie MAFFT und trimAl prozessieren. Gleichzeitig habe ich, motiviert durch massive Rechenanforderungen, rechenintensive Fortran-Modelle in eine hochmoderne **Python-Architektur unter Verwendung von Google JAX** portiert. Diese JAX-basierte Vektorisierung ermöglicht nicht nur massive Parallelisierung auf GPUs/TPUs, sondern belegt meine Fähigkeit, enorme und komplexe Datenmengen effizient architektonisch zu durchdringen – eine direkte Voraussetzung, um Sequenzierungsdaten zur Hit-Identifikation und Affinitätssteigerung algorithmisch zu bewerten.

Darüber hinaus verfüge ich über stringente **R-Projekterfahrung (Bioconductor, Tidymodels)**. Für ein Medizintechnik-Unternehmen habe ich kürzlich eine monolithische R-Pipeline für klinische Registerdaten (143.000 Datensätze, knapp 2.000 Variablen) grundlegend refaktoriert, modularisiert und für maximale Reproduzierbarkeit abgesichert. Ich spreche fließend die Sprache der Softwareentwicklung (Git, Linux, BASH) und verfüge gleichzeitig über das tiefe biologische und biostatistische Verständnis, um mit Ihren Protein-Engineering-Teams auf Augenhöhe zu kommunizieren und deren Anforderungen in Skripte, Dashboards und Tools zur Diversitätsanalyse zu übersetzen.

Mich reizt die Möglichkeit, bei Octapharma an der direkten Translation – der Entwicklung rekombinanter Proteine mit verbesserter Verträglichkeit für Patienten – mitzuwirken. In einer multidisziplinären Einheit sehe ich meine Stärke darin, der experimentellen Biologie durch überlegene algorithmische Infrastruktur und Datenanalyse den Rücken freizuhalten und die strategische Auswertung von NGS-Daten voranzutreiben.

Ich stehe Ihnen ab sofort zur Verfügung und freue mich sehr darauf, in einem persönlichen Gespräch zu diskutieren, wie ich die bioinformatischen Workflows Ihrer Abteilung verstärken kann.

Mit freundlichen Grüßen



Dr. Thejus Mahajan

Anlagen

Lebenslauf

(Zeugnisse und Referenzen auf Anfrage)

THEJUS MAHAJAN PH.D.

Computational Biologist & Data Scientist

+49-15259697629

thejusmahajan.github.io

@ thejus.mahajan@uni-hamburg.de

Hamburg, Germany

*30.09.1992 (Talikulam, India)

Married



PROFILE

- **Focus:** Large-scale NGS data analysis, bioinformatics pipeline architecture (Nextflow), and statistical modeling for sequence diversity.
- **Core Stack:** Python (Pandas, JAX, Scikit-learn), R (Bioconductor, Tidy-models), BASH.
- **Current Objective:** Serving as the computational anchor in biopharmaceutical R&D to build scalable NGS workflows that guide hit identification and candidate optimization.

EXPERIENCE

Internship – Bioinformatics & Data Pipeline Engineering

HealthTwist GmbH

02/2026 - 04/2026

Berlin, Germany

Clinical data research and development under Dr. Andreas Busjahn

- Refactored a 1,834-line medical data pipeline (R/tidyverse) for Germany's interventional radiology quality registry (DeGIR); 143K rows × 1,920 columns.
- Externalized 257 hardcoded rules into 8 config files; 26.5% code reduction with byte-level output verification (`identical()`).
- Identified 2 latent bugs through systematic code analysis; documented without altering pipeline behavior.
- Machine Learning workflows using the Tidymodels framework in R.

Further Training – Bioinformatics and Biostatistics

CQ Beratung + Bildung GmbH

08/2025 - 02/2026

Berlin, Germany

Application-related Bioinformatics and Biostatistics

- Programming methodology: Shell (BASH), Python (object-oriented), R.
- Bioinformatics databases (NCBI, Biopython, SQL) and sequence analysis.
- NGS analysis pipelines (Nextflow, Galaxy); structural bioinformatics.
- Clinical biostatistics (R/Bioconductor, ANOVA, PCA, HCA, survival analysis); GDPR/BDSG compliance.

Guest Scientist

Helmholtz-Zentrum Hereon, Ökosystemmodellierung

05/2025 - 10/2025

Geesthacht, Germany

Computational Biologist & Systems Modeler

- Spearheaded research modeling evolutionary processes in marine ecosystems.
- Applied advanced computational techniques to simulate long-term environmental impacts.

Job Search & German Language Learning

Hamburg, Germany

02/2025 - 04/2025

Hamburg, Germany

Active job search and German language acquisition (Goethe B1 certification).

Post-doctoral Scientist

University of Hamburg, Institute of Marine Ecosystem and Fisheries Sciences

08/2021 - 01/2025

Hamburg, Germany

Marine Ecosystem Modelling

STRENGTHS



Data Pipeline Engineering

Refactored a production medical data pipeline (1,834 lines, 143K rows), achieving 26.5% code reduction with zero behavioral regression. Byte-level verification after every change.



Complex Problem-Solving

Resolved a critical data-loss error by creating a Fortran simulation to correct for a misplaced particle detector, recalculating results using multi-sensor data.



Bioinformatics & Computational Biology

Bridged physical science expertise with modern biological workflows. Skilled in complex multidimensional array operations, JAX/GPU acceleration, sequence alignment, and multivariate statistical modeling using R (Bioconductor) and Python.

TECHNICAL SKILLS

Programming

Python (JAX, Pandas, NumPy, Scikit-learn, Biopython), R (Bioconductor, Tidymodels), SQL, BASH

Bioinformatics

Nextflow (DSL2), NGS Workflow Integration, Multiple Sequence Alignment (MAFFT), Sequence Trimming (trimAl), NCBI / Entrez

Biostatistics & ML

Deep Learning Foundations (TensorFlow, PyTorch concepts via JAX), Multivariate Analysis, PCA, Clustering, Scikit-learn, Tidymodels

Data Engineering

Hardware Acceleration (TPU/GPU), Large dataset processing (HDF5, NetCDF), Pipeline development

Tools

Linux/Unix, Git, HPC clusters, Conda

TRAINING / COURSES

IBM: Machine Learning with Python; Introduction to AI

Coursera (in progress)

High Performance Computing (HPC) Training

Jülich Supercomputing Center (JSC), Forschungszentrum Jülich

- Model Development: Developed the novel “Cyanobacteria Life Cycle” (CLC) model within the ERGOM framework for climate warming projections.
- High-Performance Computing & ML: Led the translation of a legacy Fortran continuous model into a high-performance Python simulation engine. Utilized **Google JAX** vectorization and branchless logic for massive parallelization (direct compatibility with **TPUs and GPUs**).
- This architecture established a strong foundation in tensor operations underpinning deep learning frameworks like **PyTorch** and **TensorFlow**.

Job Search

Kerala, India

📅 04/2021 - 07/2021 📍 Kerala, India

Relocation from India to Germany and active job search.

Physics Educator

Tutorwaves Solutions Inc / Freelance

📅 10/2018 - 03/2021 📍 Kerala, India

Prepared physics content for competitive examinations and coached state-level chess teams.

Ph.D. Researcher in Astrochemistry

University of Paris-Saclay

📅 10/2015 - 09/2018 📍 Orsay, France

Led atomic collision experiments, analyzed data, and modeled outcomes.

- Acquired and processed terabytes of raw data from tandem particle accelerator experiments.
- C++ signal processing, algorithm development, and molecular fragmentation modeling (KIDA database).

EDUCATION

Ph.D. in Astrochemistry

Université Paris-Saclay, Institute of Molecular Sciences (ISMO) Orsay, France

📅 09/2015 - 09/2018 📍 Orsay, France

M.Sc. in Physics

National Institute of Technology Calicut, India

📅 07/2012 - 01/2015 📍 Calicut, India

B.Sc. in Physics

University of Calicut, India

📅 06/2009 - 04/2012 📍 Thrissur, India

REFERENCES

Dr. Andreas Busjahn

abusjahn@healthtwist.de


Prof. Dr. Kai Wirtz

kai.wirtz@hereon.de

Prof. Dr. Elisa Schaum

elisa.schaum@uni-hamburg.de

Hamburg, 10 March 2026



Dr. Thejus Mahajan

MITx: 7.00x Introduction to Biology - The Secret of Life

Comprehensive coursework on genetics, biochemistry, and molecular biology.

OTHER SELECTED PROJECTS

Hepatitis Delta Virus Pipeline • GitHub

Nextflow (DSL2) pipeline for viral sequence diversity analysis: NCBI Entrez download, MAFFT alignment, trimAl trimming, Conda-managed.

JAX/TPU High-Performance Simulator • GitHub

Ported a legacy Fortran model to a modular Python architecture using Google JAX. Engineered branchless, vectorized logic for massive TPU/GPU parallelization.

Introduction to Tidymodels • GitHub

Teaching script for ML in R: recipes, parsnip, workflows, and yardstick on the Palmer Penguins dataset.

Berlin Tree Analysis • GitHub

Interactive Jupyter notebook analyzing 5 years of tree planting data using Python, Pandas, and Seaborn.

PUBLICATIONS

5 peer-reviewed articles • 🎓 Google Scholar Profile

LANGUAGES

English

● ● ● ● ●

Proficient

German

● ● ● ● ●

B1 - Goethe Certified

French

● ● ● ● ●

Intermediate

Malayalam

● ● ● ● ●

Native

Tamil

● ● ● ● ●

Proficient

Hindi

● ● ● ● ●

Intermediate