

THEJUS MAHAJAN PH.D.

Computational Biologist & Data Scientist

+49-15259697629

thejusmahajan.github.io

@ thejus.mahajan@uni-hamburg.de

Hamburg, Germany

30.09.1992 (Talikulam, Indien)

Verheiratet



PROFIL

- **Schwerpunkt:** Großangelegte NGS-Datenanalyse, Bioinformatik-Pipeline-Architektur (Nextflow) und statistische Modellierung für Sequenzdiversität.
- **Kernkompetenzen:** Python (Pandas, JAX, Scikit-learn), R (Bioconductor, Tidymodels), BASH.
- **Aktuelles Ziel:** Rechnergestützter Anker in der biopharmazeutischen F&E zum Aufbau skalierbarer NGS-Workflows, die Hit-Identifikation und Kandidatenoptimierung vorantreiben.

BERUFSERFAHRUNG

Praktikum – Bioinformatik & Datenpipeline-Engineering

HealthTwist GmbH

02/2026 - 04/2026

Berlin, Deutschland

Klinische Datenforschung und -entwicklung unter Dr. Andreas Busjahn

- Refactoring einer monolithischen 1.834-Zeilen R-Datenpipeline (tidyverse) für das interventionell-radiologische Qualitätsregister Deutschlands (DeGIR); 143.000+ Patientendatensätze von ~300 Kliniken. Reduktion auf 1.348 Zeilen (–26,5%) mit byte-identischer Ausgabe, verifiziert via `identical()`.
- Externalisierung von 257 hardcodierten Korrekturregeln in 8 Konfigurations-CSV-Dateien; ermöglicht Bearbeitung durch Nicht-Programmierer.
- Ersetzung von 357 veralteten Funktionsaufrufen in 4 Pipeline-Dateien; Modernisierung auf aktuelle tidyverse-Standards.
- Erstellung des R-Pakets `degirtools` (9 exportierte Funktionen, roxygen2-Dokumentation, devtools::`check()` bestanden) durch Extraktion wiederverwendbarer Logik aus einer 767-Zeilen-Hilfsdatei.
- Entdeckung von 2 vorbestehenden Fehlern durch systematische Codeanalyse; dokumentiert und originales Verhalten für Supervisor-Review beibehalten – Demonstration von Produktionscode-Disziplin.
- Aufbau eines interaktiven R-Shiny-Dashboards (6 Module: Übersicht, Interventionen, Komplikationen, Strahlendosen, Erfolgsraten, Info) mit plotly, DT und bslib. Deployment auf shinyapps.io mit DSGVO-konformen synthetischen Daten.
- Erstellung von Tidymodels-Lehrmaterialien (Quarto/GitHub) als Ersatz für das veraltete caret-Framework für ML-Workflows in R.

Weiterbildung – Bioinformatik und Biostatistik

CQ Beratung + Bildung GmbH

08/2025 - 02/2026

Berlin, Deutschland

Anwendungsorientierte Bioinformatik und Biostatistik

- Programmiermethodik: Shell (BASH), Python (objektorientiert), R.
- Bioinformatik-Datenbanken (NCBI, Biopython, SQL) und Sequenzanalyse.
- NGS-Analysepipelines (Nextflow, Galaxy); Strukturbioinformatik.
- Klinische Biostatistik (R/Bioconductor, ANOVA, PCA, HCA, Survival-Analyse); DSGVO/BDSG-Konformität.
- Abschlussprojekt: Erstellung einer reproduzierbaren Nextflow-(DSL2)-Pipeline für die Sequenzanalyse des Hepatitis-Delta-Virus – automatisierter NCBI-Download, MAFFT-Alignment und trimAl-Trimming mit Conda-verwalteten Abhängigkeiten (GitHub).

Gastwissenschaftler

Helmholtz-Zentrum Hereon, Ökosystemmodellierung

05/2025 - 10/2025

Geesthacht, Deutschland

Computational Biologist & Systemmodellierer

STÄRKEN



Datenpipeline-Engineering

Refactoring einer Produktions-Datenpipeline (1.834 Zeilen, 143K Datensätze, ~300 Kliniken) mit 26,5% Codereduktion. Erstellung des R-Pakets `degirtools`. Byte-Level-Verifizierung nach jeder Änderung via `identical()`.



Komplexe Problemlösung

Lösung eines kritischen Datenverlusts durch Erstellung einer Fortran-Simulation zur Korrektur eines falsch platzierten Teilchendetektors; Neuberechnung der Ergebnisse mittels Multisensor-Daten.



Bioinformatik & Computational Biology

Verbindung von physikalischer Expertise mit modernen biologischen Workflows. Versiert in komplexen multidimensionalen Array-Operationen, JAX/GPU-Beschleunigung, Sequenzalignment und multivariater statistischer Modellierung mit R (Bioconductor) und Python.

TECHNISCHE FÄHIGKEITEN

Programmierung

Python (JAX, Pandas, NumPy, Scikit-learn, Biopython), R (Bioconductor, Tidymodels), SQL, BASH

Bioinformatik

NGS-Workflow-Integration, Nextflow (DSL2), Multiple Sequenz-Alignierung (MAFFT), Sequenz-Trimming (trimAl), NCBI / Entrez

Biostatistik & ML

Deep-Learning-Grundlagen (TensorFlow, PyTorch-Konzepte via JAX), Multivariate Analyse, PCA, Clustering, Scikit-learn, Tidymodels

Dateningenieurwesen

Hardwarebeschleunigung (TPU/GPU), Verarbeitung großer, R Shiny, devtools/roxygen2er Datensätze (HDF5, NetCDF), Pipeline-Entwicklung

Werkzeuge

Linux/Unix, Git, HPC-Cluster, Conda

WEITERBILDUNG / KURSE

IBM: Machine Learning with Python; Introduction to AI

Coursera (in Bearbeitung)

- Leitung der Forschung zur Modellierung evolutionärer Prozesse in Meeresökosystemen.
- Anwendung fortgeschrittener Rechenmethoden zur Simulation langfristiger Umweltauswirkungen.
- Fertigstellung des rechnergestützten Modellierungs-Frameworks und Aufbereitung der Simulationsdaten für eine Peer-Review-Publikation.

Jobsuche & Deutschkurs

Hamburg, Deutschland

02/2025 - 04/2025 Hamburg, Deutschland

Aktive Stellensuche und Erwerb der deutschen Sprache (Goethe B1-Zertifikat).

Post-doctoral Scientist

Universität Hamburg, Institut für Marine Ökosystem- und Fischereiwiss.

08/2021 - 01/2025 Hamburg, Deutschland

Meeresökosystem-Modellierung

- Elternzeit von 01/2024 bis 12/2024.
- Modellentwicklung: Entwicklung des neuartigen "Cyanobacteria Life Cycle" (CLC)-Modells im ERGOM-Framework für Klimaerwärmungsprojektionen.
- Hochleistungsrechnen & ML: Leitung der Übersetzung eines Legacy-Fortran-Modells in eine hochperformante Python-Simulationsengine. Nutzung von Google JAX-Vektorisierung und branchless-Logik für massive Parallelisierung (direkte Kompatibilität mit TPUs und GPUs).
- Diese Architektur bildet eine starke Grundlage in Tensoroperationen, die Deep-Learning-Frameworks wie PyTorch und TensorFlow zugrunde liegen.

Berufliche Neuorientierung

Kerala, Indien

04/2021 - 07/2021 Kerala, Indien

Umzug von Indien nach Deutschland und aktive Stellensuche.

Physik-Dozent

Tutorwaves Solutions Inc / Freiberuflich

10/2018 - 03/2021 Kerala, Indien

Erstellung von Physikinhalten für Aufnahmeprüfungen und Coaching von Schachmannschaften auf Landesebene.

Doktorand in Astrochemie

Université Paris-Saclay

10/2015 - 09/2018 Orsay, Frankreich

Leitung von Atomkollisionsexperimenten, Datenanalyse und Ergebnismodellierung.

- Erfassung und Verarbeitung von Terabytes an Rohdaten aus Tandem-Teilchenbeschleunigerexperimenten.
- C++ Signalverarbeitung, Algorithmenentwicklung und molekulare Fragmentierungsmodellierung (KIDA-Datenbank).

AUSBILDUNG

Promotion in Astrochemie

Université Paris-Saclay, Institute of Molecular Sciences (ISMO) Orsay, Frankreich

09/2015 - 09/2018 Orsay, Frankreich

M.Sc. in Physik

National Institute of Technology Calicut, Indien

07/2012 - 01/2015 Calicut, Indien

B.Sc. in Physik

University of Calicut, Indien

06/2009 - 04/2012 Thrissur, Indien

High Performance Computing (HPC) Training
Jülich Supercomputing Center (JSC),
Forschungszentrum Jülich

MITx: 7.00x Introduction to Biology - The Secret of Life

Umfassende Kursarbeit zu Genetik, Biochemie und Molekularbiologie.

AUSGEWÄHLTE PROJEKTE

Hepatitis-Delta-Virus-Pipeline • GitHub

Nextflow (DSL2)-Pipeline für virale Sequenzdiversitätsanalyse: NCBI Entrez-Download, MAFFT-Alignment, trimAl-Trimming, Conda-verwaltet.

JAX/TPU Hochleistungssimulator • GitHub

Portierung eines Legacy-Fortran-Modells in eine modulare Python-Architektur mit Google JAX. Entwicklung branchless, vektorisierter Logik für massive TPU/GPU-Parallelisierung.

Introduction to Tidymodels • GitHub

Lehrskript für ML in R: recipes, parsnip, workflows und yardstick mit dem Palmer Penguins-Datensatz.

Berlin Tree Analysis • GitHub

Interaktives Jupyter-Notebook zur Analyse von 5 Jahren Baumpflanzungsdaten mit Python, Pandas und Seaborn.

PUBLIKATIONEN

5 begutachtete Fachartikel • Google Scholar Profil

SPRACHEN

Englisch ●●●●●●●●

Verhandlungssicher (C1)

Deutsch ●●●●●●●●

B1 – Goethe-Zertifikat

Französisch ●●●●●●●●

Grundkenntnisse

Malayalam ●●●●●●●●

Muttersprache

Tamil ●●●●●●●●

Verhandlungssicher

Hindi ●●●●●●●●

Grundkenntnisse

Hamburg, 11. April 2026



Dr. Thejus Mahajan