

PROFIL

- Computational Scientist (Promotion, Post-doc) mit Erfahrung in Datenpipeline-Engineering, mathematischer Modellierung und Hochleistungsrechnen.
- Kernkompetenzen: R (tidyverse), Python (JAX, Pandas), Fortran, SQL, Git.
- Aktuell: Praktikum in klinischer Datenforschung bei HealthTwiSt GmbH (medizinische Datenpipeline, 143K+ Datensätze).
- **Verfügbar ab Mitte April 2026** (nach Absprache ggf. früher).
- Offen für: Data Science, Biostatistik, Bioinformatik, klinische Datenanalyse, Research Software Engineering.

BERUFSERFAHRUNG

Praktikum – Klinische Biostatistik & Datenpipeline-Engineering HealthTwiSt GmbH

📅 02/2026 - 04/2026 📍 Berlin, Deutschland

Klinische Datenforschung und -entwicklung unter Dr. Andreas Busjahn

- Refactored a monolithic 1,834-line R data pipeline (tidyverse) for Germany's interventional radiology quality registry (DeGIR); 143,000+ patient records from ~300 clinics. Reduced to 1,348 lines (–26.5%) with byte-identical output verified via `identical()`.
- Externalised 257 hard-coded correction rules into 8 configuration CSV files, enabling non-programmer editing of business rules.
- Replaced 357 deprecated function calls across 4 pipeline files, modernising the codebase to current tidyverse standards.
- Created the `degirtools` R package (9 exported functions, roxygen2 docs, `devtools::check()` passing) by extracting reusable logic from a 767-line helper file.
- Discovered 2 pre-existing bugs through systematic code analysis; documented both and preserved original behaviour for supervisor review — demonstrating production-code discipline.
- Built an interactive R Shiny dashboard (6 modules: overview, interventions, complications, radiation doses, success rates, about) using plotly, DT, and bslib. Deployed to shinyapps.io with GDPR-safe synthetic data.
- Wrote Tidymodels teaching materials (Quarto/GitHub) replacing the legacy caret framework for ML workflows in R.

Weiterbildung – Bioinformatik und Biostatistik CQ Beratung + Bildung GmbH

📅 08/2025 - 02/2026 📍 Berlin, Deutschland

Anwendungsorientierte Bioinformatik und Biostatistik

- Programmiermethodik: Shell (BASH), Python (objektorientiert), R.
- Bioinformatik-Datenbanken (NCBI, Biopython, SQL) und Sequenzanalyse.
- NGS-Analysepipelines (Next-Generation Sequencing; Nextflow, Galaxy); Strukturbioinformatik.
- Biostatistik (R/Bioconductor): ANOVA, PCA, HCA, multivariate Analyse, Markov-Ketten.
- Abschlussprojekt: Erstellung einer reproduzierbaren Nextflow-(DSL2)-Pipeline für die Sequenzanalyse des Hepatitis-Delta-Virus — automatisierter NCBI-Download, MAFFT-Alignment und trimAl-Trimming mit Conda-verwalteten Abhängigkeiten (🔗 GitHub).

Gastwissenschaftler (parallel zur Weiterbildung ab 08/2025)

Helmholtz-Zentrum Hereon, Ökosystemmodellierung

📅 05/2025 - 10/2025 📍 Geesthacht, Deutschland

STÄRKEN



Datenpipeline-Engineering

Refactoring einer Produktions-Datenpipeline (1.834 Zeilen, 143K Datensätze) mit 26,5% Codereduktion bei null Verhaltensregression. Byte-Level-Verifizierung nach jeder Änderung.



Komplexe Problemlösung

Lösung eines kritischen Datenverlusts durch Erstellung einer Fortran-Simulation zur Korrektur eines falsch platzierten Teilchendetektors; Neuberechnung der Ergebnisse mittels Multisensor-Daten.



Bioinformatik & Biostatistik

Verbindung von physikalischer Expertise mit modernen biologischen Workflows. Versiert in NGS-Datenanalyse, Sequenzalignment und multivariater statistischer Modellierung mit R (Bioconductor) und Python.

TECHNISCHE FÄHIGKEITEN

Programmierung

R (tidyverse, dplyr, tidyr, stringr, readr, R Markdown), Python (JAX, Pandas, NumPy), Fortran, C++, SQL, BASH

Dateningenieurwesen

Pipeline-Refactoring, konfigurationsgetriebene Architektur, `identical()`-Verifizierung, Verarbeitung großer Datensätze (HDF5, NetCDF)

Bioinformatik

NGS-Analyse, Nextflow (DSL2), Sequenzanalyse, Bioconductor

Biostatistik

Multivariate Analyse, PCA, ANOVA, Dimensionality Reduction, Tidymodels

Werkzeuge

Git/GitHub (Branching, kollaborative Workflows), Linux/Unix, HPC-Cluster, Conda, LaTeX

SPRACHEN

Englisch



Verhandlungssicher (C1)

Deutsch



B1 (Goethe-Zertifikat), B2 in Vorbereitung

Französisch



Grundkenntnisse

Modellierung evolutionärer Prozesse in Meeresökosystemen; Simulation langfristiger Umweltauswirkungen mittels fortgeschrittener Rechenmethoden. Fertigstellung des rechnergestützten Modellierungs-Frameworks und Aufbereitung der Simulationsdaten für eine Peer-Review-Publikation.

Jobsuche & Deutschkurs

📅 02/2025 - 04/2025 📍 Hamburg, Deutschland

Aktive Stellensuche und Erwerb der deutschen Sprache (Goethe-Zertifikat B1).

Wissenschaftlicher Mitarbeiter (Post-doc)

Universität Hamburg, Institut für Marine Ökosystem- und Fischereiwiss.

📅 08/2021 - 01/2025 📍 Hamburg, Deutschland

Meeresökosystem-Modellierung

- Elternzeit von 01/2024 bis 12/2024.
- Modellentwicklung: Entwicklung des "Cyanobacteria Life Cycle" (CLC)-Modells im ERGOM-Framework für Klimaerwärmungsprojektionen.
- Hochleistungsrechnen (HPC): Übersetzung eines Legacy-Fortran-Modells in eine hochperformante Python-Engine (Google JAX, TPU/GPU-Parallelisierung). Verarbeitung großer NetCDF-Datensätze in Linux-HPC-Umgebung.

Berufliche Neuorientierung

📅 04/2021 - 07/2021 📍 Hamburg, Deutschland

Umzug von Indien nach Deutschland und aktive Stellensuche.

Physik-Dozent & Schachtrainer

Freiberuflich / Tutorwaves Solutions Inc (ab 08/2020)

📅 10/2018 - 03/2021 📍 Kerala, Indien

Freiberufliche Physik-Nachhilfe und Coaching von Schachmannschaften auf Landesebene; ab 08/2020 bei Tutorwaves: Erstellung von Physikhalten und Betreuung von Schülern in den USA und Australien.

Doktorand in Astrochemie

Université Paris-Saclay

📅 10/2015 - 09/2018 📍 Orsay, Frankreich

Durchführung von Atomkollisionsexperimenten, Datenanalyse und Ergebnismodellierung.

- Erfassung und Verarbeitung von Terabytes an Rohdaten aus Tandem-Teilchenbeschleunigerexperimenten.
- C++ Codeoptimierung: Verbesserung bestehender Algorithmen zur Rauschunterdrückung, Signalglättung und Konvertierung von Rohdaten in mehrdimensionale Strukturen.
- Entwicklung eines molekularen Fragmentierungsmodells zur Vorhersage chemischer Reaktionen im Weltraum (Beitrag zur KIDA-Datenbank).

AUSBILDUNG

Promotion in Astrochemie

Université Paris-Saclay, Institute of Molecular Sciences (ISMO)

📅 10/2015 - 09/2018 📍 Orsay, Frankreich

Diss.: *Excitation and fragmentation of C_nN^+ ($n=1-3$) in collisions with He atoms at intermediate velocity.*

M.Sc. in Physik

National Institute of Technology Calicut, Indien

📅 07/2012 - 12/2014 📍 Calicut, Indien

Mit Auszeichnung (CGPA 8,71/10).

Forschungsprojekt – Theoretische Atomphysik

IIT Mandi (unter Dr. Hari Varma)

📅 02/2015 - 08/2015 📍 Mandi, Indien

Theoretische Atomphysik; teilweise remote.

B.Sc. in Physik

University of Calicut, Indien

📅 06/2009 - 04/2012 📍 Thrissur, Indien

B+ (CGPA 3,49/4,0). Anschl. 05–06/2012: Aufnahmeprüfung und Zulassung zum M.Sc.

Malayalam



Muttersprache

Tamil



Verhandlungssicher

Hindi



Grundkenntnisse

WEITERBILDUNG / KURSE

High Performance Computing (HPC) Training

Jülich Supercomputing Center (JSC),
Forschungszentrum Jülich

MITx: 7.00x Introduction to Biology – The Secret of Life

Umfassende Kursarbeit zu Genetik, Biochemie und Molekularbiologie.

PUBLIKATIONEN

T. Mahajan et al. *J. Phys.: Conf. Ser.*, 1412:142026, 2020.

T. Idbarkach et al. *Astron. Astrophys.*, 628:A75, 2019.

T. Mahajan et al. *J. Phys. B*, 2019.

T. Idbarkach et al. *J. Phys. B*, 51(24):245201, 2018.

T. Idbarkach et al. *J. Phys.: Conf. Ser.*, 1412(11):112028, 2020.

🎓 Google Scholar Profil

Hamburg, 11. April 2026

Dr. Thejus Mahajan